

Curso de Engenharia de Software

TRABALHO FINAL PRÁTICO **Inteligência Artificial** *Ênfase em Lógica Fuzzy e Machine Learning*

Autores:

Joelma Giovanna B. F. Rocha - UC23200743
Késia Silva Viana - UC23200887
Luciana Liebl de Freitas - UC23200568
Larissa Kailane Lima Vieira da Veiga - UC23100470

Professor: William Roberto Malvezzi

1. Introdução

1.1 Apresentação do Problema e Contexto de Aplicação

De acordo com o Instituto Unibanco (2021), a evasão escolar ocorre quando o estudante, seja reprovado ou aprovado, não efetua a matrícula para dar continuidade aos estudos no ano seguinte, sendo um problema complexo que envolve uma série de fatores. Nesse sentido, a evasão escolar gera impactos negativos que vão desde o prejuízo financeiro e operacional para as instituições de ensino até o impacto social e pessoal na vida dos estudantes que interrompem sua formação escolar, técnica ou profissional.

Nesse contexto, este trabalho busca analisar o comportamento dos estudantes a partir de múltiplos fatores acadêmicos, para mapear padrões comportamentais de risco antes que o abandono de fato se concretize.

1.2 Justificativa da Solução

A escolha por uma solução baseada em Inteligência Artificial justifica-se pela incapacidade dos métodos tradicionais de gestão escolar em prever a evasão de forma preditiva e individualizada em larga escala, considerando vários fatores.

Nesse viés, a fim de trazer uma solução capaz de transformar dados acadêmicos em conceitos linguísticos e gerar um risco final interpretável, a abordagem usada neste trabalho integra o Machine Learning e a Lógica Fuzzy.

Assim, por um lado, o algoritmo de Machine Learning possui alta capacidade computacional para extrair padrões ocultos e realizar classificações precisas a partir de volumes massivos de dados históricos. Enquanto a Lógica Fuzzy permite traduzir variáveis numéricas exatas em termos linguísticos de fácil interpretação humana (como frequência "baixa" ou engajamento "médio").

Dessa forma, a integração dessas técnicas garante um sistema de alta acurácia preditiva e uma solução altamente interpretável, permitindo que gestores educacionais compreendam perfeitamente as razões que levaram o sistema a classificar um determinado aluno como de "alto risco" e, consequentemente, possibilitando que a instituição de ensino se torne capaz de adotar estratégias para evitar a evasão e conter os riscos da operação de forma mais assertiva.

1.3 Objetivo geral do trabalho

O objetivo deste trabalho é desenvolver e implementar uma solução computacional prática de Inteligência Artificial para apoiar a tomada de decisão institucional, integrando modelos de Machine Learning e Lógica Fuzzy para analisar

indicadores acadêmicos e estimar, de forma precisa e interpretável, o risco de evasão de estudantes.

2. Fundamentação Teórica

Explicação dos conceitos de Inteligência Artificial, Machine Learning, classificação e regressão, algoritmo escolhido, Lógica Fuzzy, conjuntos fuzzy, variáveis linguísticas, funções de pertinência e regras de inferência.

2.1 Inteligência Artificial e Machine Learning

A Inteligência Artificial (IA) é um campo da ciência da computação que se ocupa da automação do comportamento inteligente (MALVEZZI, 2026), ou seja, é o ramo voltado ao desenvolvimento de sistemas que executa tarefas que, tradicionalmente, exigiriam a inteligência humana, como percepção visual, tomada de decisão e tradução de idiomas.

Nesse contexto, dentro do campo de estudo da IA, existe uma subárea chamada de Machine Learning, traduzida para o português como Aprendizado de Máquina, que é focada na construção de algoritmos capazes de aprender e fazer previsões sobre dados. Assim, esses algoritmos funcionam construindo um modelo a partir de entradas amostrais com a finalidade de aprender padrões, fazer previsões ou decisões guiadas pelos dados ao invés de simplesmente seguirem instruções programadas inflexíveis e estáticas (MALVEZZI, 2026).

Logo, enquanto na inteligência artificial existem dois tipos de raciocínio, o indutivo e o dedutivo, o aprendizado de máquina só se preocupa com o indutivo, que extrai regras e padrões de grandes conjuntos de dados (MALVEZZI, 2026).

Dessa forma, de acordo com a EngDB (2024), o aprendizado de máquina se divide em quatro principais categorias dependendo da presença e do tipo de supervisão humana nos dados: Aprendizado Supervisionado, Aprendizado Semi Supervisionado, Aprendizado Não supervisionado e Aprendizado por Esforço.

Para fins deste trabalho, destaca-se o Aprendizado Supervisionado, que segundo a IBM (2026), se caracteriza pela existência de um modelo que é treinado a partir de um conjunto de dados rotulados, ou seja, a variável resultado é conhecida e abrange os seguintes tipos de algoritmos com base na natureza da variável-alvo:

- **Algoritmos de classificação:** O objetivo é prever uma categoria ou rótulo para uma dada entrada, por exemplo, “Risco de Crédito” pode ser classificado com o rótulo “alto”, “médio” ou “baixo” (MALVEZZI, 2026).
- **Algoritmos de regressão:** O objetivo é estimar um valor numérico, por exemplo, “Risco de Investimento” a saída seria um valor, como 95% de possibilidade de retorno do investimento (MALVEZZI, 2026).

2.2 O Algoritmo Escolhido: Árvore de Decisão

O algoritmo de Machine Learning escolhido para este projeto foi a Árvore de Decisão (Decision Tree), em razão da facilidade de interpretação dos seus resultados. O algoritmo de Árvore de Decisão funciona a partir de árvores que são treinadas de acordo com um conjunto de treino (exemplos previamente classificados) e posteriormente, outros exemplos são classificados de acordo com essa mesma árvore (MALVEZZI, 2026).

Como explica a IBM (2026), uma Árvore de Decisão utiliza uma estrutura ramificada para segmentar dados com base em diferentes condições, funcionando tanto para problemas de classificação quanto de regressão. Esse processo cria uma estrutura hierárquica semelhante a um fluxograma, composto por:

- **Nó Raiz:** O ponto de partida que contém a primeira grande divisão baseada no atributo mais informativo.
- **Nós Internos (Decisão):** Pontos onde novas condições e perguntas sobre os dados são avaliadas.
- **Folhas:** Os nós terminais que representam a decisão final ou a classificação do modelo.

Assim, com esse tipo de estrutura de fluxograma cria-se uma representação fácil da tomada de decisões, possibilitando que fique mais legível o entendimento do porquê uma decisão foi tomada. Com isso, o caminho percorrido da raiz até a folha pode ser facilmente traduzido em regras lógicas do tipo "SE... ENTÃO", facilitando a comparação direta com a Lógica Fuzzy.

2.3 Lógica Fuzzy

Diferente da lógica booleana tradicional, nas quais as proposições são unicamente o verdadeiras (1) ou falsas (0), a Lógica Fuzzy estende essa fronteira para permitir graus intermediários de verdade. Proposta por Lotfi A. Zadeh em 1965, ela possibilita a representação matemática de incertezas, imprecisões e conceitos subjetivos que fazem parte do cotidiano e do raciocínio humano (RIGNEL; CHENCI; LUCAS, 2011)

A estrutura de um Sistema de Inferência Fuzzy é composta por conceitos fundamentais:

- **Conjuntos Fuzzy e Funções de Pertinência:** na teoria clássica de conjuntos, um elemento pertence ou não pertence a ele. Em um conjunto fuzzy, os elementos possuem um grau de pertinência que varia continuamente no intervalo $[0, 1]$. Esse grau é mapeado pelas Funções de Pertinência, que quantifica o grau em que um elemento pertence a um conjunto fuzzy (MALVEZZI, 2026).

- **Variáveis Linguísticas:** São variáveis cujos valores não são números brutos, mas sim palavras ou frases de uma linguagem natural. Por exemplo, em vez de tratarmos a frequência apenas como o número "72%", ela é modelada semanticamente através de termos linguísticos como "baixa", "média" ou "alta" (PUC-RIO).
- **Regras de Inferência:** Formam a base de conhecimento do sistema fuzzy. Elas são estruturadas por meio de condicionais lógicas (SE antecedente, ENTÃO consequente) escritas em linguagem natural e construídas a partir do conhecimento do especialista sobre o domínio do problema. Elas conectam as variáveis linguísticas de entrada para determinar o comportamento e a tomada de decisão da variável de saída (PUC-RIO).

3. Descrição da Base de Dados

3.1 Origem da base

Nossa base de dados foi gerada por simulação estocástica, ou seja, utilizamos três perfis comportamentais (baixo, médio e alto). Cada registro foi gerado individualmente com variações aleatórias dentro de intervalos definidos, garantindo heterogeneidade e realismo dos dados.

Criamos um notebook separado para a implementação da base de dados, seguindo as orientações dos tipos de variáveis sugeridos na atividade proposta. Para a etapa de Lógica Fuzzy, a utilização de uma base simulada mostrou-se ainda mais adequada, pois permite o controle das variáveis e a definição de regras mais intuitivas e coerentes com o comportamento esperado do modelo. Dessa forma, foi possível estruturar um conjunto de dados consistente e controlado, facilitando a aplicação de técnicas de análise e modelagem.

3.2 Quantidade de registros

A base de dados simulada contém 300 registros, representando 300 estudantes.

3.3 Atributos utilizados:

- Frequência;
- Notas;
- Participação no AVA;
- Atividades entregues;
- Reprovações anteriores;
- Atraso em atividades.

3.4 Variável-alvo:

A variável-alvo definida foi o Risco de Evasão, categorizado em três níveis: Baixo, Médio e Alto, com base no perfil de desempenho acadêmico dos estudantes.

3.5 Limitações identificadas:

Por se tratar de uma base simulada, não há dados reais de estudantes, o que pode limitar a representação fiel de comportamentos reais. Além disso, as variáveis foram geradas de forma probabilística, o que pode não refletir totalmente a complexidade dos fatores que influenciam a evasão escolar. Outra limitação é a ausência de variáveis externas, como contexto socioeconômico ou psicológico, que também poderiam impactar o risco de evasão.

4. Pré-processamento dos Dados

Para garantir a qualidade e a consistência das análises efetuadas tanto pelo algoritmo de Machine Learning quanto pelo Sistema de Inferência Fuzzy, a base de dados contendo os 300 registros passou por uma etapa de pré-processamento estruturada em três fases essenciais:

- **Verificação de Consistência e Valores Ausentes:** Foi aplicada uma rotina programática para identificar a presença de dados nulos (NaN ou null) nas colunas do dataset. A verificação indicou que a base de dados simulada possui 0% de valores ausentes em todos os atributos (Frequência, Nota, Participação no AVA, Atividades Entregues, Reprovações e Atrasos), dispensando a necessidade de técnicas de imputação (como substituição pela média ou mediana).
- **Transformação de Variáveis Categóricas (Label Encoding):** A variável-alvo Risco_Evasao original continha os rótulos de texto ordenáveis "Baixo", "Médio" e "Alto". Para que o algoritmo de Machine Learning pudesse processá-la, utilizou-se a classe LabelEncoder da biblioteca scikit-learn. Essa técnica mapeou as categorias textuais em valores numéricos inteiros equivalentes, mantendo a compatibilidade com a modelagem matemática.
- **Divisão entre Treino e Teste:** Com o objetivo de treinar o classificador e posteriormente validar sua capacidade de generalização em dados não vistos, a base de dados foi dividida utilizando o método `train_test_split`. Adotou-se uma proporção clássica de 80% para o conjunto de treinamento e 20% para o conjunto de teste. Para assegurar a reprodutibilidade dos experimentos e garantir que as mesmas divisões ocorressem em futuras execuções do código, fixou-se o parâmetro `random_state`.

5. Modelo de Machine Learning

5.1 Algoritmo Escolhido e Justificativa

O modelo supervisionado escolhido para realizar a classificação do risco de evasão foi a Árvore de Decisão (DecisionTreeClassifier). A escolha baseia-se em dois fatores críticos para o contexto educacional:

- **Alta Interpretabilidade:** A estrutura em forma de fluxograma gerada pelo algoritmo permite que os gestores pedagógicos compreendam visualmente o caminho lógico e os critérios de corte adotados para classificar um estudante em determinado nível de risco.
- **Extração de Regras Práticas:** As ramificações da árvore partindo do nó raiz até os nós folhas podem ser mapeadas diretamente em regras lógicas condicionais ("SE... ENTÃO"), o que viabiliza uma comparação direta e uma integração robusta com as regras que governam o Sistema Fuzzy.

5.2 Processo de Treinamento e Resultados

O modelo foi treinado sobre o conjunto de dados de treino correspondente às seis variáveis de entrada numéricas. Configurando o critério de divisão e uma profundidade máxima controlada para evitar o sobreajuste (overfitting), a árvore de decisão extraiu os padrões comportamentais ocultos da base de dados.

Após o treinamento, o modelo foi submetido ao conjunto de testes, alcançando os seguintes resultados:

- **Acurácia Geral:** 95,00%, demonstrando uma alta taxa de acerto na classificação dos alunos nos perfis de risco correto.
- **Profundidade da Árvore:** O algoritmo estruturou-se de forma otimizada em 5 níveis de profundidade.
- **Importância dos Atributos:** A análise de relevância revelou que a variável Participacao_AVA (Participação no Ambiente Virtual de Aprendizagem) foi o atributo mais informativo (maior ganho de informação), atuando como o principal divisor no nó raiz do modelo para separar os alunos propensos à evasão daqueles com engajamento estável.

6. Sistema Fuzzy

6.1 Definição das Variáveis, Universo de Discurso e Termos Linguísticos

Para capturar as incertezas e a imprecisão inerentes ao comportamento humano e pedagógico, foi desenvolvido um Sistema de Inferência Fuzzy do tipo Mamdani utilizando a biblioteca scikit-fuzzy. Foram selecionadas três variáveis críticas

de entrada e uma variável de saída, mapeadas em seus respectivos Universos de Discurso (intervalos numéricos) e associadas a termos linguísticos representados por funções de pertinência triangulares (trimf):

- **Frequência (Variável de Entrada):**
 - Universo de Discurso: [0,100] (representando a porcentagem de presença).
 - Termos Linguísticos: "baixa" [0,0,60], "média" [50,70,85] e "alta" [75,100,100].
- **Nota (Variável de Entrada):**
 - Universo de Discurso: [0,10] (média das avaliações do estudante).
 - Termos Linguísticos: "baixa" [0,0,5], "média" [4,6,8] e "alta" [7,10,10].
- **Engajamento (Variável de Entrada):**
 - Universo de Discurso: [0,100] (métrica unificada que sintetiza os acessos ao AVA e entrega de atividades).
 - Termos Linguísticos: "baixo" [0,0,45], "médio" [30,50,70] e "alto" [55,100,100].
- **Risco de Evasão (Variável de Saída):**
 - Universo de Discurso: [0,100] (índice percentual do risco final computado).
 - Termos Linguísticos: "baixo" [0,0,35], "médio" [25,50,75] e "alto" [65,100,100].

6.2 Regras de Inferência e Mecanismo de Computação

A base de conhecimento do sistema foi estruturada a partir de 8 regras fuzzy do tipo SE... ENTÃO, modeladas para refletir o raciocínio de especialistas da área educacional:

1. SE frequência é baixa E nota é baixa, ENTÃO risco final é alto.
2. SE frequência é média E engajamento é baixo, ENTÃO risco final é médio.
3. SE frequência é alta E nota é alta, ENTÃO risco final é baixo.
4. SE nota é baixa E engajamento é baixo, ENTÃO risco final é alto.
5. SE frequência é média E nota é média E engajamento é médio, ENTÃO risco final é médio.
6. SE frequência é alta E engajamento é alto, ENTÃO risco final é baixo.
7. SE nota é alta E engajamento é alto, ENTÃO risco final é baixo.
8. SE frequência é baixa OU engajamento é baixo, ENTÃO risco final é alto.

O processo computacional realiza a fuzzificação das entradas numéricas exatas do aluno, aplicando-as sobre as curvas de pertinência. Em seguida, o motor de inferência combina os operadores lógicos (E/OU) das regras ativas e, por fim, executa a defuzzificação por meio do Método do Centróide, convertendo a região fuzzy

resultante em um valor numérico contínuo e exato entre 0 e 100, indicando a intensidade do risco.

7. Integração ou Comparação

Nesta etapa, realizou-se uma análise comparativa e fundamentada entre as previsões geradas pelo modelo de Machine Learning (Árvore de Decisão) e as saídas numéricas do Sistema de Inferência Fuzzy para todos os 300 registros da base de dados. Para viabilizar a comparação direta, os resultados contínuos do sistema fuzzy (0 a 100) foram categorizados em três classes de risco com base em faixas de corte: Risco Baixo (0 a 35), Risco Médio (35 a 65) e Risco Alto (65 a 100).

Os modelos apresentaram uma taxa de concordância de 84,00%, demonstrando uma elevada sinergia e convergência na identificação dos perfis de estudantes. As divergências pontuais observadas (16% dos casos) ocorreram predominantemente nas fronteiras cinzentas entre as transições de risco "Baixo para Médio" e "Médio para Alto".

Essas discrepâncias revelam a complementaridade das abordagens: enquanto a Árvore de Decisão traça cortes rígidos e matemáticos exatos com base nos dados históricos obtidos no processo de treinamento (encontrando que a participação no AVA possui o maior ganho de informação), a Lógica Fuzzy gerencia com maior suavidade as transições de comportamento através de suas sobreposições de conjuntos, evitando que variações milimétricas em uma nota mudem drasticamente o status de um estudante sem considerar o contexto global das outras variáveis.

8. Resultados e Discussão

Nesta seção, são apresentados os resultados numéricos, qualitativos e gráficos obtidos a partir dos experimentos, detalhando o comportamento dos dados, o desempenho dos modelos e os casos de teste específicos aplicados para validar o ecossistema de Inteligência Artificial.

Os resultados obtidos evidenciam a eficiência de ambas as ferramentas para a mitigação da evasão escolar. A tabela abaixo apresenta a distribuição quantitativa exata das classificações de risco geradas a partir dos 300 registros do dataset:

Modelo / Origem	Risco Baixo	Risco Médio	Risco Alto
Rótulo Real (Dataset)	63	100	137
Machine Learning (ML)	61	103	137
Sistema Fuzzy	62	146	92

8.1 Análise Visual do Comportamento dos Dados

Antes da modelagem, a base de dados contendo os 300 registros simulados passou por uma análise estatística e exploratória para compreender a distribuição e relevância das características coletadas.




Figura 1: Distribuição das Variáveis do Dataset de Evasão.

Conforme observado na figura 1, a distribuição das variáveis comportam-se de forma a delimitar claramente os extremos (alunos com frequência e notas excelentes versus alunos com alta taxa de atrasos e reprovações). Essa separação inicial foi fundamental para o sucesso do treinamento do modelo de Machine Learning.




Figura 2: Importância das Variáveis para a Árvore de Decisão.

O gráfico de barras da Figura 2 quantifica o ganho de informação (feature importance) de cada atributo. A variável Participacao_AVA destaca-se como o indicador preditivo mais forte, seguida de perto por Nota e Frequencia. Atributos como Atrasos e Reprovacoes, embora relevantes, exercem menor peso isolado na decisão final do classificador.

8.2 Desempenho do Modelo de Machine Learning

O classificador baseado em Árvore de Decisão (DecisionTreeClassifier) foi treinado com 80% dos dados e validado com os 20% restantes (equivalente a uma subamostra de teste de 60 alunos), alcançando uma acurácia geral de 95,00%.




Figura 3: Estrutura Externa da Árvore de Decisão Gerada

Na Figura 3 exibe a árvore de decisão expandida em 5 níveis. O nó raiz utiliza a Participacao_AVA com um limiar matemático exato para realizar a primeira grande divisão dos estudantes. A visualização dos nós folhas comprova a alta interpretabilidade do modelo, permitindo extrair regras puras do tipo "SE... ENTÃO" para auditoria pedagógica.




Figura 4: Matriz de Confusão do Conjunto de Testes (ML).

A matriz de confusão (Figura 4) mapeia os erros e acertos textuais sobre os 60 alunos do grupo de teste. O modelo classificou perfeitamente as classes "Alto" e "Baixo". Os erros observados limitaram-se a apenas 3 instâncias da classe "Médio" que foram erroneamente classificadas como "Alto" ou "Baixo". Essa taxa residual marginal indica que as fronteiras intermediárias são as únicas zonas de sutil ambiguidade para o algoritmo preditivo.

Distribuição do Risco de Evasão




Figura 5: Proporção Geral do Risco de Evasão por Machine Learning.

O gráfico de setores (Figura 5) resume a visão do Machine Learning sobre toda a base. O modelo categorizou a maior parte dos alunos em risco Alto (137) e Médio (102), desenhando um cenário realista de evasão institucional que exige intervenções urgentes.

8.3 Modelagem, Comportamento e Funções do Sistema Fuzzy

Diferente da rigidez matemática da Árvore de Decisão, o Sistema Fuzzy processa as incertezas por meio de conceitos linguísticos e mapeamentos contínuos.




Figura 6: Funções de Pertinência para as Variáveis Fuzzy.

A Figura 6 expõe as curvas triangulares (trimf) criadas para transicionar as variáveis (Frequência, Nota, Engajamento e Risco Final). As zonas de interseção entre as curvas (por exemplo, onde uma nota 5.5 pertence parcialmente ao conjunto "Média" e "Baixa") são o núcleo que permite ao sistema suavizar a tomada de decisão, aproximando-a do julgamento de um especialista humano.




Figura 7: Dispersão e Agrupamento (Boxplot) do Risco Fuzzy por Categoria.

O gráfico de caixas (Figura 7) comprova que o método de defuzzificação por Centróide distribuiu os scores de risco de forma consistente. Alunos classificados como risco "Alto" concentram-se estritamente acima do score 65, demonstrando uma excelente calibração das 8 regras de inferência estruturadas no motor.

8.4 Casos de Teste Práticos Aplicados (Simulações de Validação)

Para testar a robustez e o comportamento em tempo real do sistema híbrido, foram injetados perfis de casos de teste extremos e intermediários diretamente no código compilado. A tabela a seguir documenta os testes de estresse aplicados:

Cas o de Test e	Perfil do Aluno Avaliado	Entrada Fuzzy Aplicada	Saída Numéric a Fuzzy	Classificaçã o Fuzzy	Predichã o Machine Learnin g
01	Aluno Crítico (Evasão Iminente): Frequência zerada, notas vermelhas e sem interações no ambiente virtual.	Frequência: 45% Nota: 2.0 Engajamento : 15%	81.36	Risco Alto	Risco Alto
02	Aluno Regular/Intermediário: Desempenho mediano em todas as frentes, com entregas parciais.	Frequência: 70% Nota: 6.0 Engajamento : 50%	50.00	Risco Médio	Risco Médio
03	Aluno Excelente (Sem Risco): Presença integral, notas máximas e engajamento constante.	Frequência: 95% Nota: 9.5 Engajamento : 90%	18.63	Risco Baixo	Risco Baixo

Análise dos Casos de Teste:

- No Caso 01, ambos os modelos convergiram para o Risco Alto. O sistema Fuzzy gerou um score contínuo severo de 81.36, ativando prioritariamente as Regras 1 e 8 ("SE frequência é baixa OU engajamento é baixo...").
- No Caso 02, as curvas de transição posicionaram o aluno exatamente no centro geométrico do gráfico (50.00), comprovando que o método do centróide equilibrou com precisão as nuances de um aluno mediano.
- No Caso 03, o score caiu para 18.63 (Risco Baixo), validando a perfeita calibração do sistema para não gerar alarmes falsos em estudantes estáveis.

8.5 Comparação Geral e Interpretação Crítica dos Achados

Por fim, cruzou-se a classificação final de cada um dos 300 alunos obtida pelas duas metodologias distintas de Inteligência Artificial.




Figura 8: Comparação de Classificações: Machine Learning vs Sistema Fuzzy.

Conforme evidenciado na Figura 8, os modelos alcançaram uma taxa de concordância de 84,00%. A árvore de decisão tendeu a classificar mais alunos nos extremos ("Alto" ou "Baixo") por possuir cortes binários e rígidos de separação de dados históricos.

Em contrapartida, o Sistema Fuzzy classificou um volume significativamente maior de estudantes como Risco Médio (146 casos). Longe de ser um erro, esse comportamento revela o caráter preventivo da lógica nebulosa: ao detectar pequenas oscilações correlacionadas (como uma nota ligeiramente menor acompanhada de uma sutil queda de acessos), o sistema eleva o nível do aluno para "Médio" de forma cautelar. Para a gestão da Universidade Católica de Brasília, essa sensibilidade é altamente desejável, pois funciona como um gatilho preventivo de monitoramento antes que a situação do estudante se degenere para uma evasão escolar irreversível.

Conclusão

O presente trabalho cumpriu com êxito o objetivo proposto de desenvolver e avaliar uma solução prática de Inteligência Artificial voltada à previsão do risco de evasão acadêmica na Engenharia de Software. Através da construção de uma base de dados simulada de 300 estudantes, foi possível consolidar os conhecimentos teóricos ministrados em sala de aula de maneira prática e integrada.

A fusão das duas frentes demonstrou que o Machine Learning provê uma precisão matemática excepcional para detectar padrões rígidos de comportamento (95% de acurácia), enquanto a Lógica Fuzzy fornece a flexibilidade necessária para interpretar a subjetividade e as nuances do engajamento estudantil, traduzindo números brutos em conceitos linguísticos compreensíveis. Como melhorias e trabalhos futuros, sugere-se a expansão do modelo com a inclusão de variáveis reais de natureza socioeconômica e psicopedagógica, bem como a automação da extração das regras fuzzy diretamente a partir dos nós folhas da árvore de decisão treinada, otimizando ainda mais a concordância e a calibração do sistema de inferência.

9. Referências

ENGDB. Tipos de aprendizado de máquina. Blog EngDB, [s. l.], [2024]. Disponível em: <https://blog.engdb.com.br/tipos-de-aprendizado-de-maquina/>. Acesso em: 16 jun. 2026.

GOOGLE COLAB. Notebook compartilhado – projeto de base de dados. Disponível em: <https://colab.research.google.com/drive/1Ty2871iTNtyyAN32Eiz9sL8jQn1Mou2P?usp=sharing>. Acesso em: 14 jun. 2026.

IBM. Árvores de decisão. IBM Think, [s. l.], 2026. Disponível em: <https://www.ibm.com/br-pt/think/topics/decision-trees>. Acesso em: 17 jun. 2026.

IBM. Tipos de aprendizado de máquina. IBM Think, [s. l.], 2026. Disponível em: <https://www.ibm.com/br-pt/think/topics/machine-learning-types>. Acesso em: 16 jun. 2026.

INSTITUTO UNIBANCO. Evasão escolar e o abandono: um guia para entender esses conceitos. Observatório de Educação – Ensino Médio e Gestão, [s. l.], [2021]. Disponível em: <https://observatoriodeeducacao.institutounibanco.org.br/em-debate/abandono-evasao-escolar>. Acesso em: 15 jun. 2026.

MALVEZZI, William. Slides da disciplina de Inteligência Artificial: Introdução a IA. Material interno, 2026. Acesso em: 16 jun. 2026.

MALVEZZI, William. Slides da disciplina de Inteligência Artificial: Machine Learning. Material interno, 2026. Acesso em: 16 jun. 2026.

MALVEZZI, William. Slides da disciplina de Inteligência Artificial: Teoria Fuzzy. Material interno, 2026. Acesso em: 16 jun. 2026.

PUC-RIO. Lógica Fuzzy. Rio de Janeiro: Sistema Maxwell/PUC-Rio, [201-?]. Capítulo 3. Disponível em: https://www.maxwell.vrac.puc-rio.br/32823/32823_3.PDF. Acesso em: 17 jun. 2026.

RIGNEL, Daniel G. S.; CHENCI, G. P.; LUCAS, C. A. Uma introdução à lógica fuzzy. Revista Eletrônica de Sistemas de Informação e Gestão Tecnológica (RESIGeT), Franca, v. 1, n. 1, p. 17-28, 2011. Disponível em: <http://periodicos.unifacef.com.br/resiget/article/view/153>. Acesso em: 17 jun. 2026.